

CBIR

Content-Based Image Retrieval

com Ponderação Espacial via IoU

Dataset: Intel Image Classification · Kaggle

buildings

forest

glacier

mountain

sea

street

~25.000 imagens · 150×150 px · 6 classes de cenas naturais

1. O QUE É CBIR?

Content-Based Image Retrieval

Definição

Técnica de busca que recupera imagens visualmente similares a uma **imagem de entrada (query)** — sem depender de palavras-chave, tags ou metadados.

O sistema analisa o conteúdo visual: **cores, texturas, formas e gradientes** — e usa essas informações para medir similaridade.

Texto vs. Conteúdo

Critério	Texto	CBIR
Entrada	Palavra-chave	Imagem
Compara	Tags e metadados	Pixels e features
Anotação manual	Sim (obrigatório)	Não necessário
Exemplo	"floresta verde"	Esta foto aqui

2. O DATASET

Intel Image Classification · Kaggle (puneet6060)

~25.000

Imagens

150×150

Pixels (RGB)

6

Classes

3

Conjuntos

As 6 Classes de Cenas

Classe	Características Visuais Típicas	Nº docs
buildings	Linhas retas, concreto/vidro, tons cinzas	~2.190
forest	Verde dominante, folhagem densa	~2.271
glacier	Branco/azul, neve e gelo, formas irregulares	~2.404
mountain	Picos triangulares, marrom/cinza, céu visível	~2.512
sea	Azul dominante, horizonte nítido, textura d'água	~2.274
street	Perspectiva em fuga, asfalto, elementos urbanos	~2.383

3. PIPELINE DO SISTEMA

6 etapas sequenciais — da imagem bruta ao resultado ranqueado

$$\text{Score}(q, r) = \alpha \times \text{CosineSim}(\text{feat}_q, \text{feat}_r) + (1-\alpha) \times \text{IoU}(\text{bbox}_q, \text{bbox}_r)$$

1 Carregamento

Seleciona docs do seg_train e queries do seg_test. Cria bbox central 70%.

2 Prop. Regiões

Sliding window multi-escala: imagem completa, bandas horizontais, escalas 50/65/80%.

3 Extração Features

HOG + LBP + Histograma HSV + Momentos. Vetor ~439-dim por região.

4 Indexação

Empilha todos os vetores. Normaliza L2. Matriz (N_reg × 439).

5 Sweep α/β

Testa $\alpha \in \{0.0...1.0\}$. Escolhe o que maximiza mAP nas queries.

6 Busca & Rank

Calcula CosSim + IoU. Colapsa por imagem. Retorna top-K.

ETAPA 3 — EXTRAÇÃO DE DESCRITORES

Cada região é convertida em um vetor numérico de ~439 dimensões

HOG · Histogram of Oriented Gradients

~324 dim

Captura estrutura de bordas e gradientes locais. Divide a imagem em células 8x8px e cria histogramas de 9 orientações.

↳ **Para Intel:** Distingue prédios (bordas verticais), montanhas (diagonais) e floresta (bordas difusas).

LBP · Local Binary Pattern

10 dim

Para cada pixel, compara com 8 vizinhos em raio 1.5 e gera um padrão binário de textura.

↳ **Para Intel:** Diferencia neve granular, folhagem densa, superfície de água e asfalto rugoso.

Hist HSV · Histograma de Cor HSV

96 dim

Histograma com 32 bins para cada canal H, S, V. O matiz (H) é altamente discriminativo para cenas.

↳ **Para Intel:** Mar=pico em azul, floresta=verde, glacier=baixa saturação, rua=tons neutros.

Momentos · Momentos Estatísticos HSV

9 dim

Média, desvio padrão e assimetria (skewness) de cada canal H, S e V.

↳ **Para Intel:** Glacier tem brilho alto e saturação baixa. Floresta tem alta variação de brilho.


Total: ~439 dimensões · Normalizado L2 → Similaridade Coseno

4. IoU — INTERSECTION OVER UNION

Componente de similaridade espacial/posicional das regiões

Fórmula

$$\text{IoU}(A, B) = \text{Área}(A \cap B) / \text{Área}(A \cup B)$$



Resultado: **0.0** = sem sobreposição | **1.0** = idênticas

↳ Área de sobreposição = mais escura nos dois retângulos

Por que usar IoU no CBIR?

Incorpora a posição espacial das regiões como critério secundário de ranqueamento — imagens de cena similar tendem a ter elementos visuais na mesma posição.

IoU	Significado
1.0	Sobreposição perfeita
0.5–0.9	Sobreposição significativa
0.1–0.5	Sobreposição parcial
0.0	Sem sobreposição

$$\text{Score} = 0.9 \times \text{VisSim} + 0.1 \times \text{IoU}$$

5. MÉTRICAS DE AVALIAÇÃO

Como medimos a qualidade da recuperação?

Precision@K

$$P@K = \text{Acertos}(\text{top-K}) / K$$

Fração de acertos entre os primeiros K resultados. Mede a qualidade dos resultados mais relevantes.

Ex: Top-5: [sea, sea, mnt, sea, sea] $\rightarrow P@5 = 4/5 = 0.80$

Recall@K

$$R@K = \text{Acertos}(\text{top-K}) / \text{Total_relevantes}$$

Fração de TODAS as imagens relevantes que foram encontradas nos top-K resultados.

Ex: 25 docs 'sea', 5 nos top-10 $\rightarrow R@10 = 5/25 = 0.20$

F1@K

$$F1 = 2 \times P@K \times R@K / (P@K + R@K)$$

Média harmônica de P@K e R@K. Penaliza sistemas bons em apenas uma métrica.

Ex: $P@5=0.80$, $R@5=0.60 \rightarrow F1@5 = 0.69$

mAP

$$AP = \Sigma[P@k \times \text{rel}(k)] / N_{\text{rel}} \quad | \quad \text{mAP} = \text{média das APs}$$

Área sob a curva P-R. Penaliza erros no início da lista mais que no final. mAP é a média sobre todas as queries.

Ex: $\text{mAP}=1.0$ perfeito $\cdot >0.5$ bom $\cdot 0.17 = \text{acaso}$ (6 classes)

6. SAÍDAS DO SISTEMA

5 arquivos gerados automaticamente na pasta de saída

Imagem PNG

cbir_intel_dashboard.png

Dashboard completo com 6 painéis: AP por classe, sweep α/β , P/R/F1, matriz de similaridade, curvas P-R, Precision@K e strips de recuperação visual (query + top-5 resultados por classe).

Relatório PDF

cbir_intel_report.pdf

PDF de múltiplas páginas: capa com tabela de métricas, gráficos de avaliação, e uma página por query com top-11 resultados e decomposição do score (VisSim vs IoU vs Combined).

JSON

results.json

Todas as métricas (P@5, P@10, R@5, R@10, F1@5, AP, curvas P-R) e lista de imagens ranqueadas para cada query, em formato estruturado para análise posterior.

JSON

sweep.json

Registro completo do sweep α/β : para cada valor de α testado (0.0 a 1.0), o mAP obtido. Permite analisar a sensibilidade do sistema ao balanceamento visual vs. espacial.

NumPy Array

sim_matrix.npy

Matriz numpy ($N_{\text{docs}} \times N_{\text{docs}}$) com as similaridades coseno entre todos os documentos indexados. Pode ser carregada e visualizada externamente como heatmap.